山东大学软件学院

面向股价预测的
大规模文本信息处理技术研究与实现

指导老师
谷元

答辩人
软件3班许崇杨

目录

CONTENTS

选题背景

PART ONE

整体设计

PART TWO

股价涨跌预测

PART THREE

选题背景

PART ONE

“大数据”

“大数据”技术发展，开源框架涌现，大数据处理门槛降低
许多行业开始应用“大数据”技术

“量化投资”

运用数学或者统计模型来模拟金融市场的未来走向，从而预估金融产品的潜在收益
人们开始将机器学习应用于量化投资

“新闻中的倾向性影响股市”

本文提出在大量新闻极性分析基础上进行股价涨跌预测的方法
这需要大规模文本采集和分析处理的技术

整体设计

PART TWO

整体处理流程

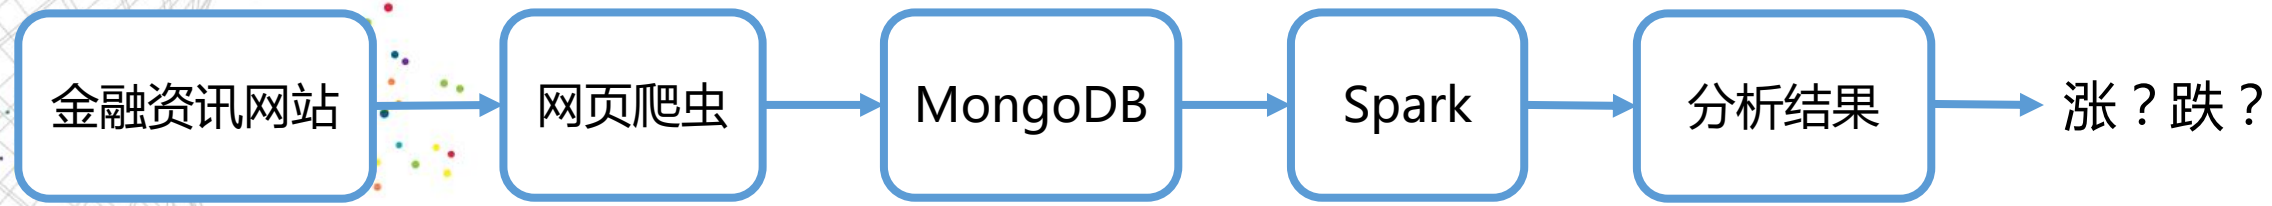

采集程序结构

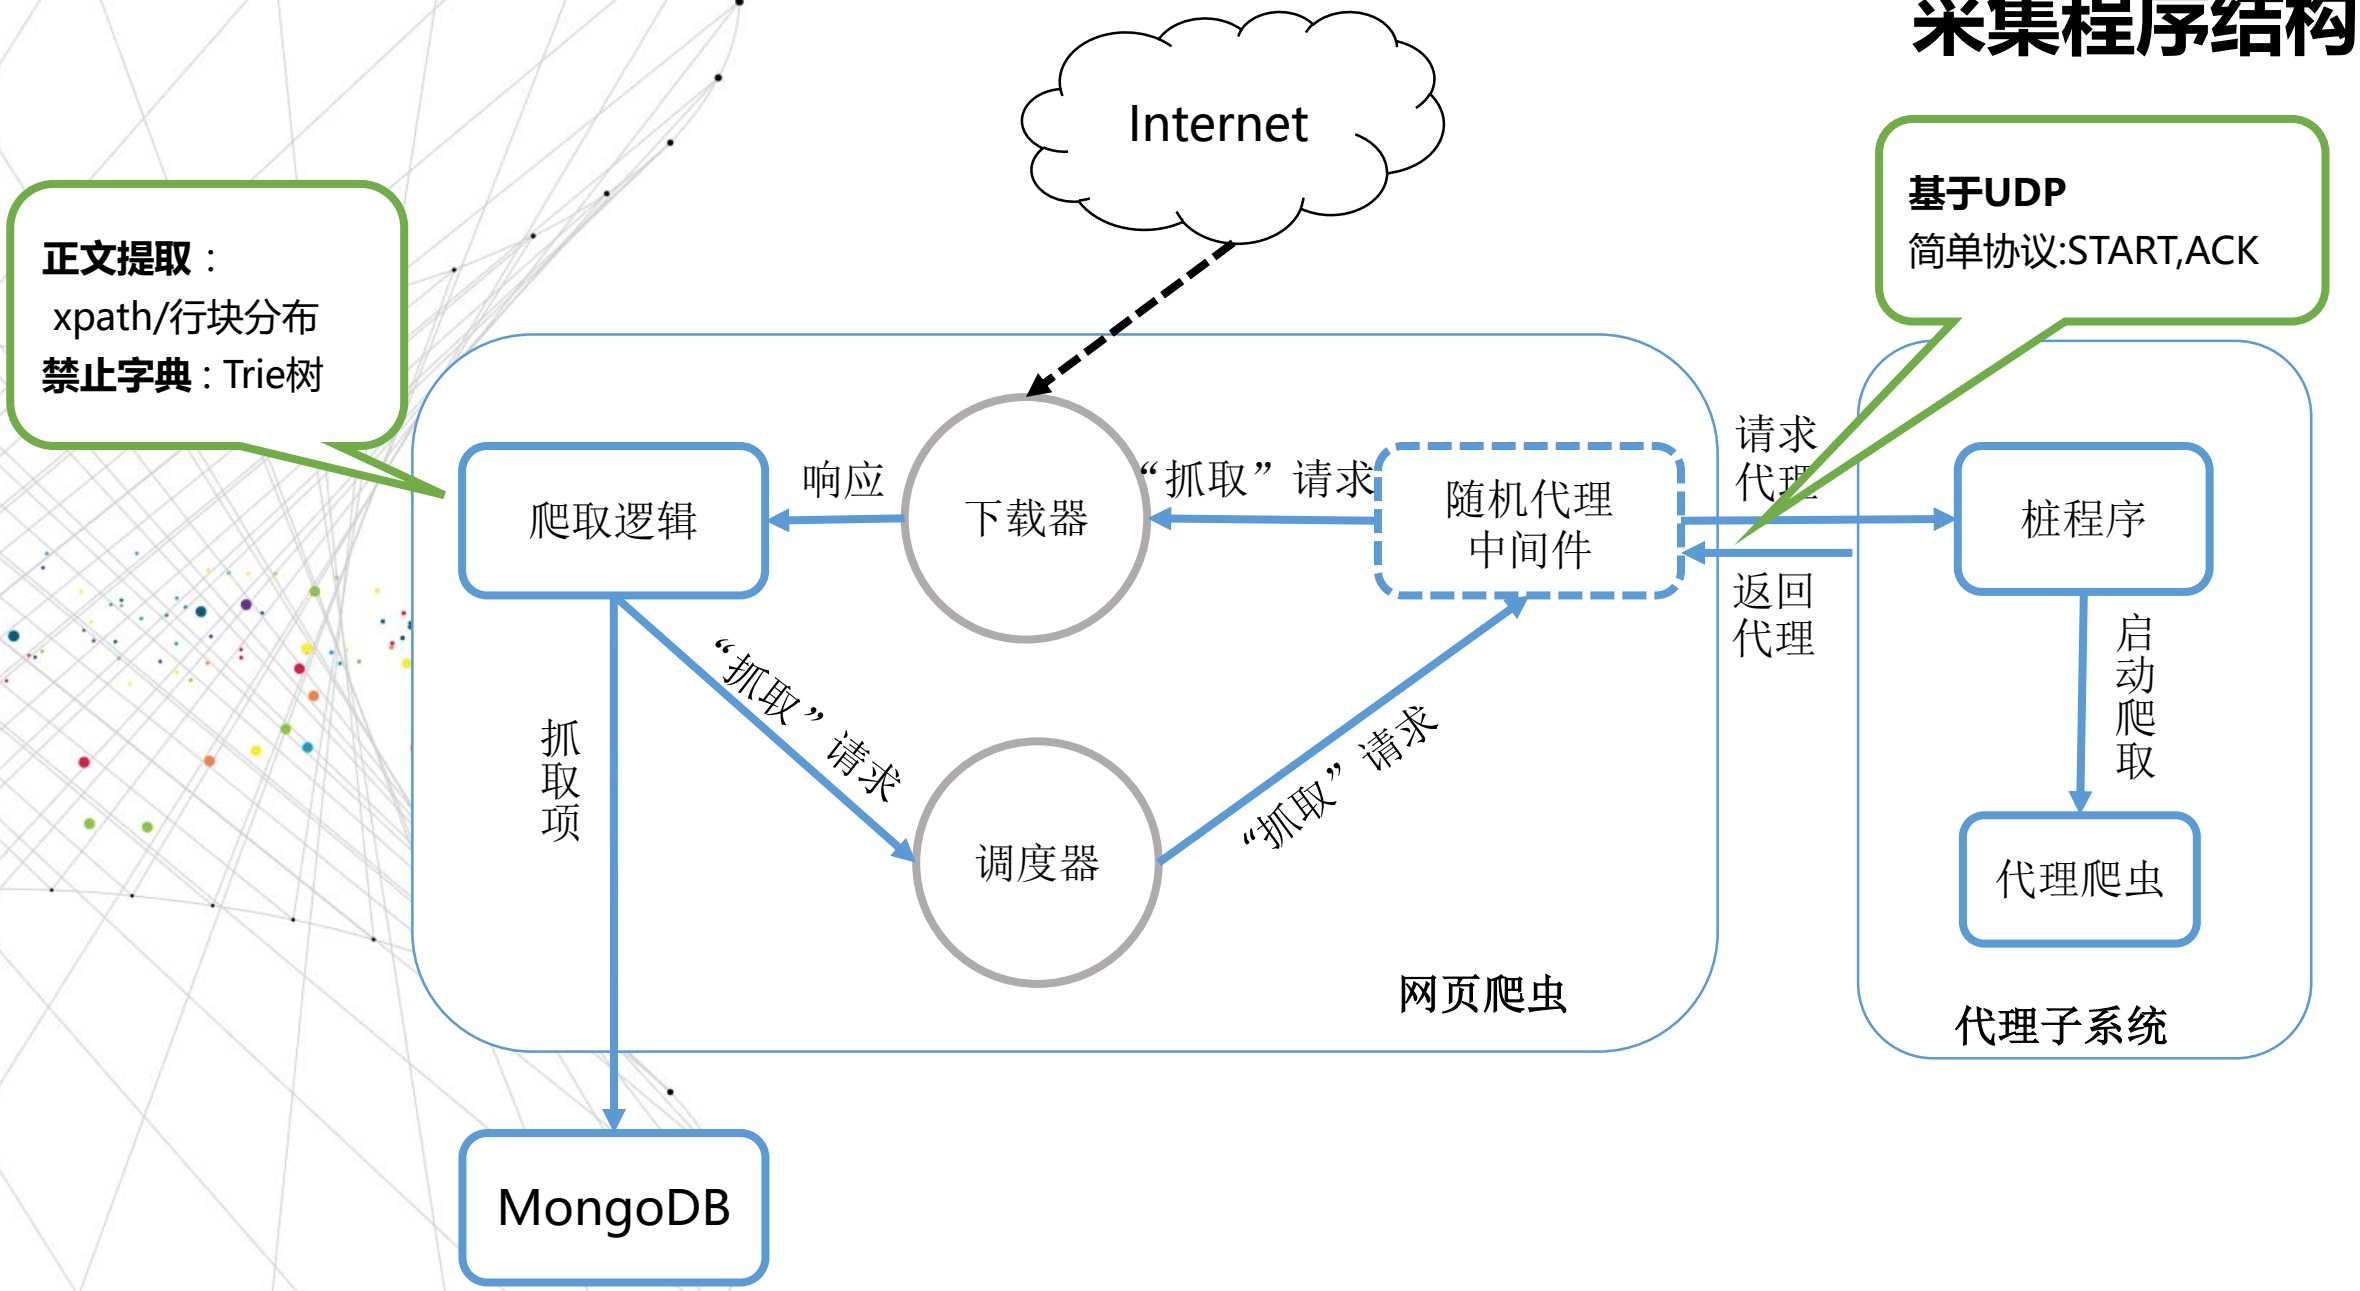
Internet
正文提取：
xpath/行块分布
禁止字典：Trie树
基于UDP
简单协议:START,ACK
爬取逻辑
响应
下载器
“抓取”请求
随机代理
中间件
请求
代理
返回
代理
桩程序
启动
爬取
代理爬虫
抓
取
项
“抓取”请求
调度器
“抓取”请求
网页爬虫
代理子系统
MongoDB

分析程序结构

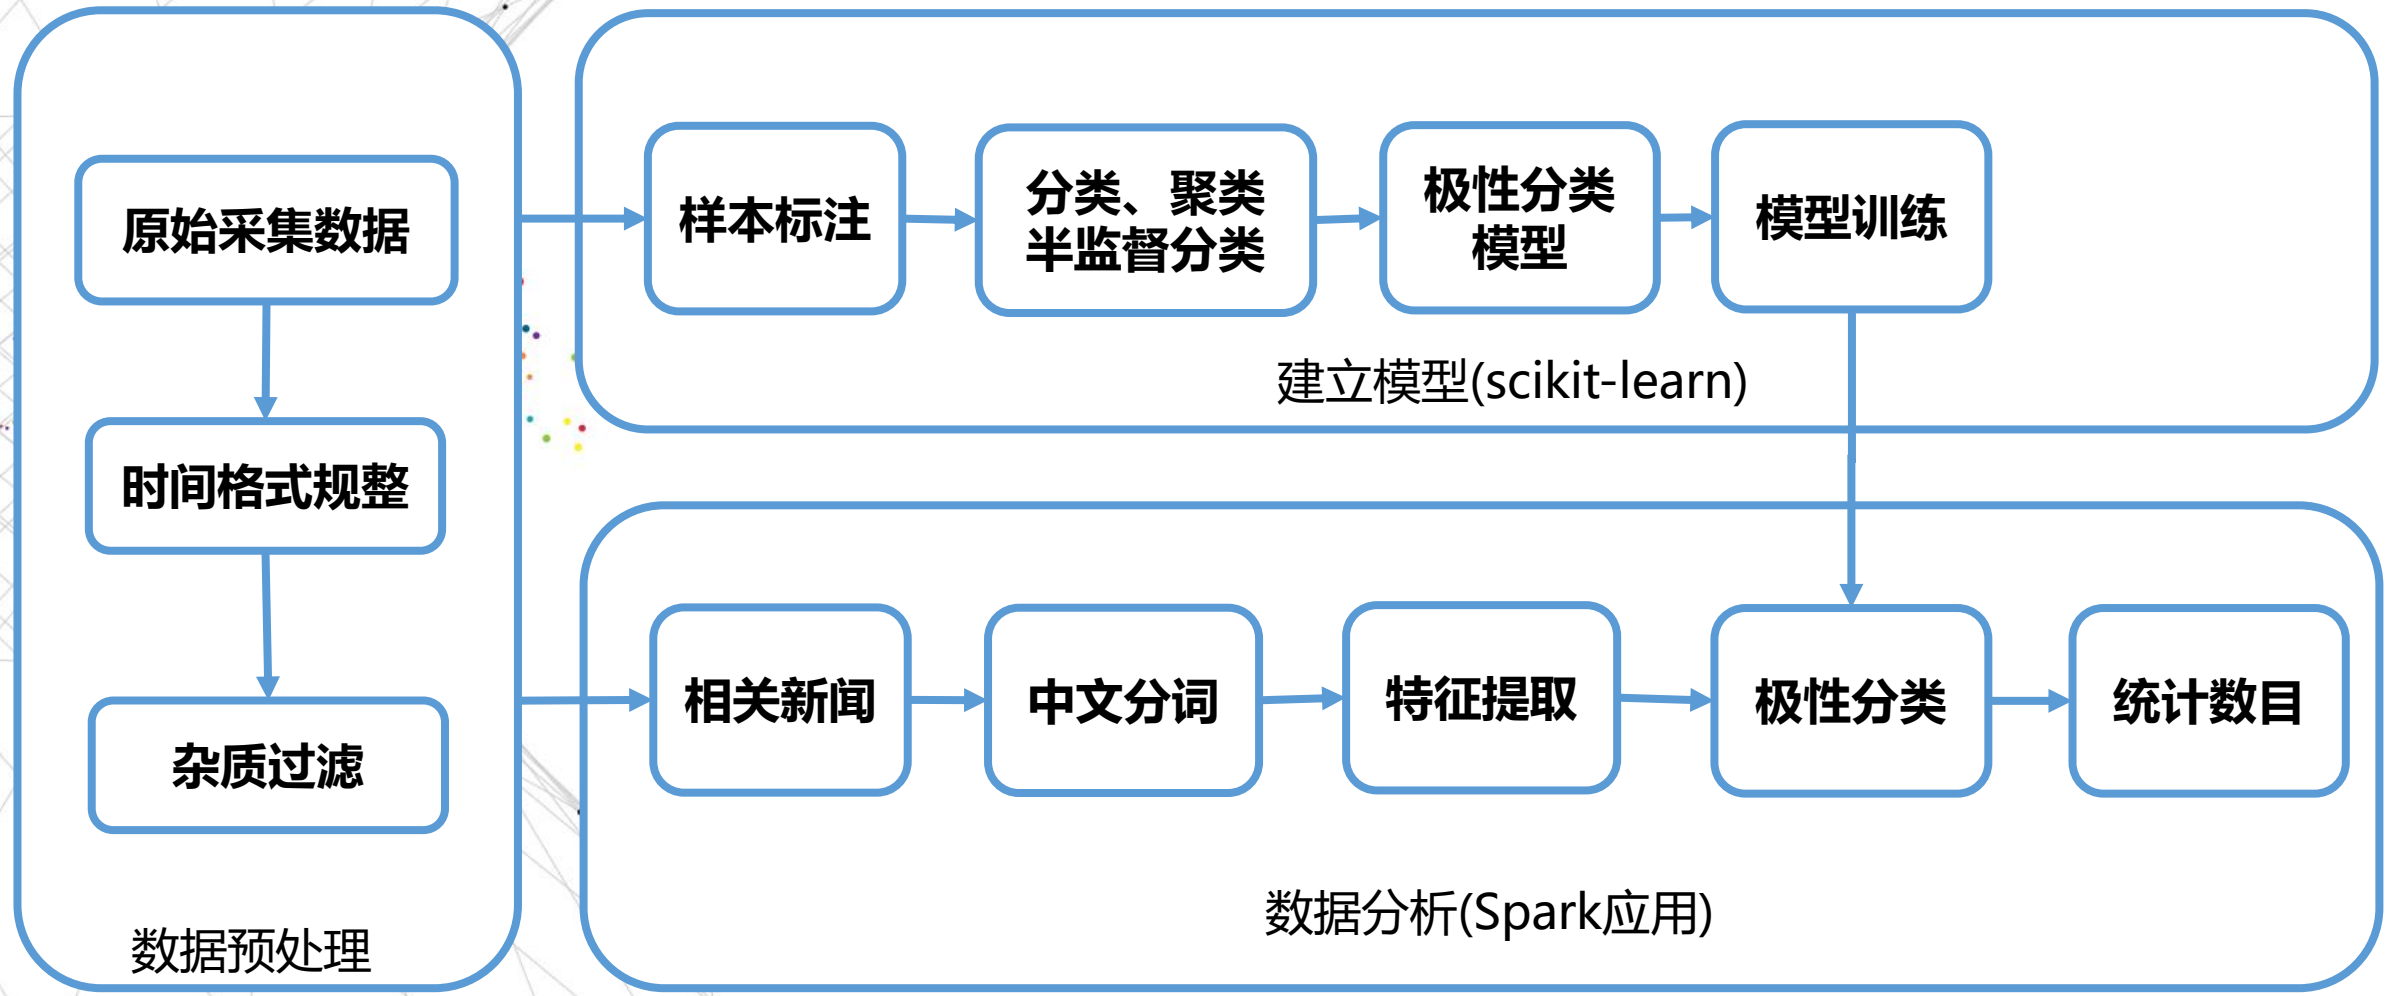
原始采集数据
时间格式规整
杂质过滤
数据预处理
样本标注
分类、聚类
半监督分类
极性分类
模型
模型训练
建立模型(scikit-learn)
相关新闻
中文分词
特征提取
极性分类
统计数目
数据分析(Spark应用)

股价涨跌预测

PART THREE

新闻极性分类

没有语料(中文、金融、新闻极性)：手动标注1000句样本

“词袋”法提取特征，台湾大学NTUSD-简体中文情感极性词典

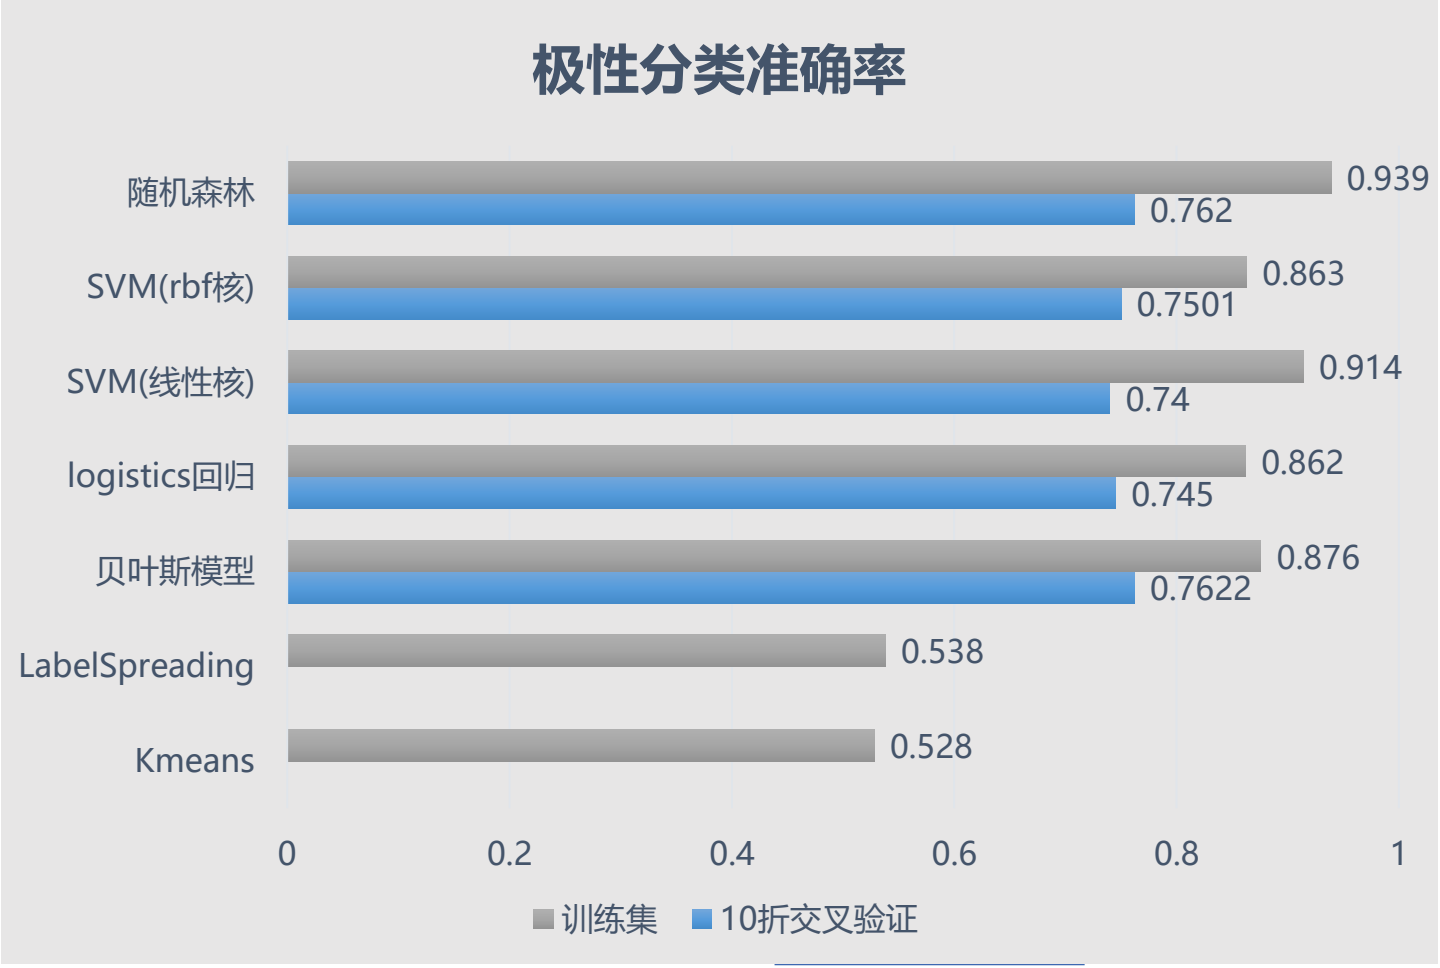

股价涨跌预测

(#pos,#neg)

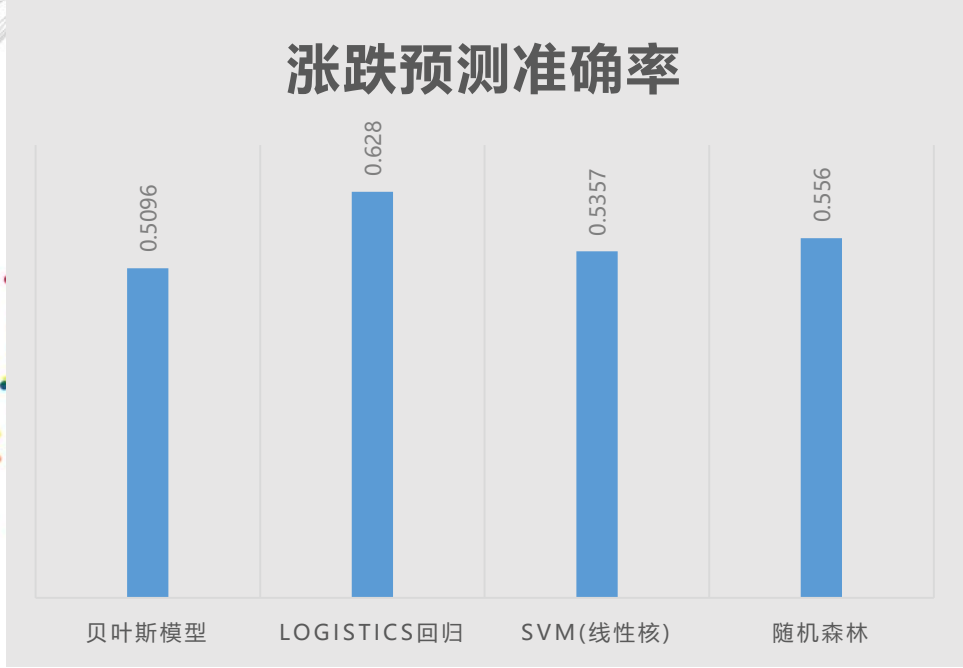

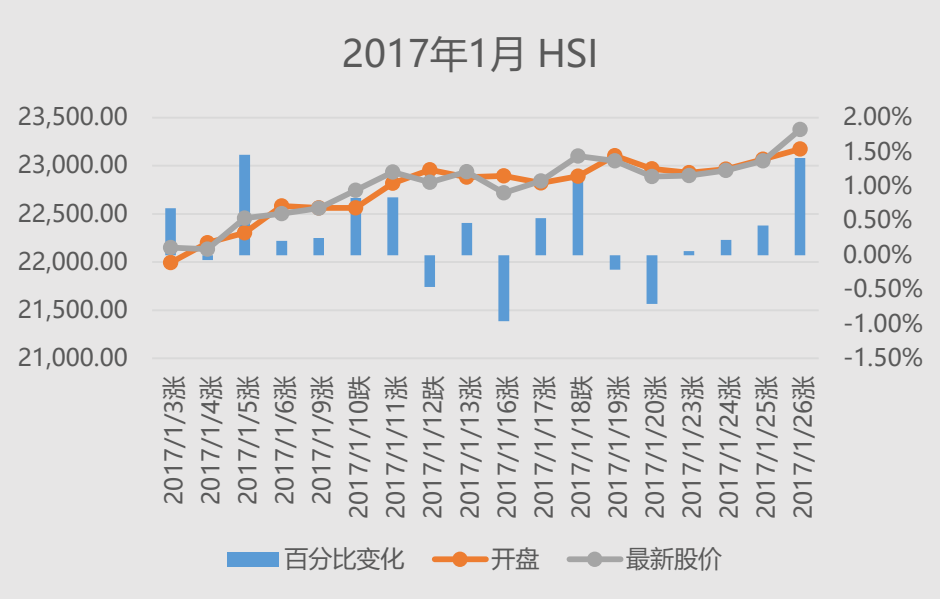

1月份预测错误：4日,10日,11日,18日,19日,20日,共6天。

模拟交易(2017年1/3~1/26，假设每次1股/100元)

简单投机策略： 盈利3.85元

前一天涨买入；前一天跌卖出；(持有)前一天涨持有

基于涨跌预测： 盈利4.8元

预测当天涨买入；预测当天跌卖出； (持有)预测当天涨持有

总结

给出了一个大规模文本信息采集和分析工具的设计，可供类似任务参考

建立了一个中文新闻句子的极性分类模型，准确率达74%

股价涨跌准预测确率达62%，模拟交易显示有助于提高投资收益

不足：

极性分类样本较少

投入更多人力标注更多样本，有助于提高极性分类准确率，可能会使得涨跌预测准确率上升，使投资者收益更多

谢谢观看！

指导老师
谷元

答辩人
软件3班许崇杨